Метод опорных векторов

11 октября 2025 г.

Содержание

1. Метод опорных векторов SVM
   - Принцип оптимальной разделяющей гиперплоскости
   - Двойственная задача
   - Понятие опорного вектора
2. Обобщения линейного SVM
   - Ядра и спрямляющие пространства
   - SVM как двухслойная нейронная сеть
   - SVM-регрессия
3. Регуляризация
   - Регуляризаторы для отбора признаков
   - Методы SFM и RFM
   - Метод релевантных векторов RVM

Задача обучения линейного классификатора

Дано:

Обучающая выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$,
x_i — объекты, векторы из множества $X = \mathbb{R}^n$,
y_i — метки классов, элементы множества $Y = \{-1, +1\}$.

Найти:

Параметры $w \in \mathbb{R}^n$, $w_0 \in \mathbb{R}$ линейной модели классификации

$$a(x; w, w_0) = \text{sign}\left(\langle x, w\rangle - w_0\right).$$

Критерий — минимизация эмпирического риска:

$$\sum_{i=1}^{\ell} [a(x_i; w, w_0) \neq y_i] = \sum_{i=1}^{\ell} [M_i(w, w_0) < 0] \to \min_{w, w_0}.$$

где $M_i(w, w_0) = (\langle x_i, w\rangle - w_0) y_i$ — отступ (margin) объекта x_i,

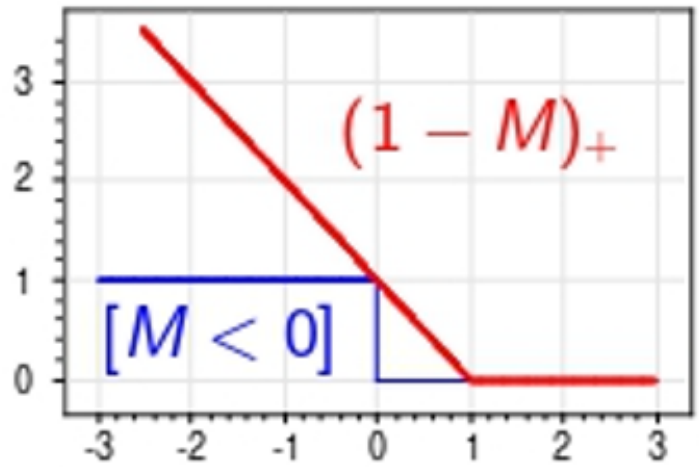
Аппроксимация и регуляризация эмпирического риска

Эмпирический риск — это кусочно-постоянная функция.
Заменим его оценкой сверху, непрерывной по параметрам:

$$Q(w, w_0) = \sum_{i=1}^{\ell} [M_i(w, w_0) < 0] \leq$$

$$\leq \sum_{i=1}^{\ell} (1 - M_i(w, w_0))_+ + \frac{1}{2C} w^2 \to \min_{w, w_0}.$$

- Аппроксимация штрафует объекты за приближение к границе классов, увеличивая зазор между классами
- Регуляризация штрафует неустойчивые решения в случае мультиколлинеарности



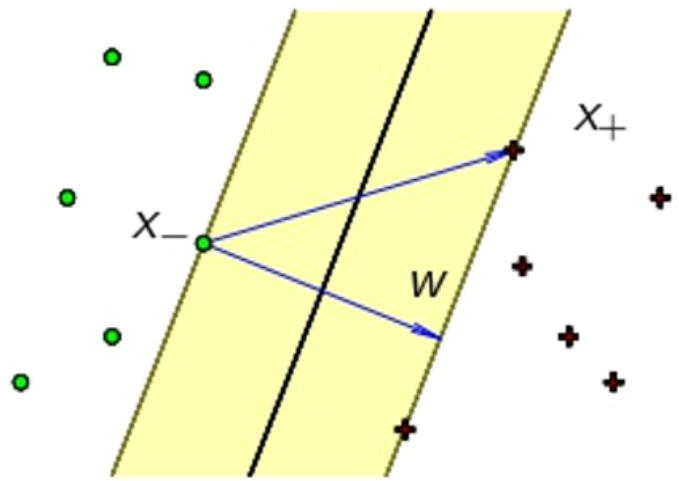
Оптимальная разделяющая гиперплоскость

Линейный классификатор: $a(x, w) = \text{sign}(\langle w, x\rangle - w_0)$
Пусть выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$ линейно разделима:

$$\exists w, w_0 : M_i(w, w_0) = y_i(\langle w, x_i\rangle - w_0) > 0, \quad i = 1, \ldots, \ell$$

Нормировка: $\min_{i=1,\ldots,\ell} M_i(w, w_0) = 1$
Разделяющая полоса (разделяющая гиперплоскость посередине):

$$\begin{aligned}
\{x : \quad & -1 \le \langle w, x\rangle - w_0 \le 1\} \\
\exists x_+ : \quad & \langle w, x_+\rangle - w_0 = +1 \\
\exists x_- : \quad & \langle w, x_-\rangle - w_0 = -1
\end{aligned}$$



Ширина полосы:

$$\frac{\langle x_+ - x_-, w\rangle}{\|w\|} = \frac{2}{\|w\|} \to \max$$

Обоснование кусочно-линейной функции потерь

Линейно разделимая выборка:

$$\begin{cases} \frac{1}{2}\|w\|^2 \to \min_{w,w_0}; \\ M_i(w, w_0) \geq 1, \quad i = 1, \ldots, \ell. \end{cases}$$

Переход к линейно неразделимой выборке (эвристика):

$$\begin{cases} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{\ell} \xi_i \to \min_{w,w_0,\xi}; \\ \xi_i \geq 1 - M_i(w, w_0), \quad i = 1, \ldots, \ell; \\ \xi_i \geq 0, \quad i = 1, \ldots, \ell. \end{cases}$$

Эквивалентная задача безусловной минимизации:

$$C\sum_{i=1}^{\ell}(1 - M_i(w, w_0))_+ + \frac{1}{2}\|w\|^2 \to \min_{w,w_0}.$$

Напоминание. Условия Карруша-Куна-Таккера (ККТ)

Задача математического программирования:

$$\begin{cases} f(x) \to \min_x; \\ g_i(x) \le 0, \quad i = 1, \ldots, m; \\ h_j(x) = 0, \quad j = 1, \ldots, k. \end{cases}$$

Необходимые условия. Если x — точка локального минимума, то существуют множители $\mu_i, \quad i = 1, \ldots, m$, $\lambda_j, \quad j = 1, \ldots, k$:

$$\begin{cases} \frac{\partial \mathscr{L}}{\partial x} = 0, \quad \mathscr{L}(x; \mu, \lambda) = f(x) + \sum_{i=1}^{m} \mu_i g_i(x) + \sum_{j=1}^{k} \lambda_j h_j(x); \\ g_i(x) \le 0; \quad h_j(x) = 0; \quad \text{(исходные ограничения)} \\ \mu_i \ge 0; \quad \text{(двойственные ограничения)} \\ \mu_i g_i(x) = 0; \quad \text{(условие дополнительной нежёсткости)} \end{cases}$$

Применение условий ККТ к задаче SVM

Функция Лагранжа:

$$\mathscr{L}(w, w_0; \xi, \lambda, \eta) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C),$$

где λ_i — переменные, двойственные к ограничениям $M_i \geq 1 - \xi_i$;
η_i — переменные, двойственные к ограничениям $\xi_i \geq 0$.

$$\begin{cases} \frac{\partial \mathscr{L}}{\partial w} = 0, \quad \frac{\partial \mathscr{L}}{\partial w_0} = 0, \quad \frac{\partial \mathscr{L}}{\partial \xi} = 0; \\ \xi_i \geq 0, \quad \lambda_i \geq 0, \quad \eta_i \geq 0, \quad i = 1, \ldots, \ell; \\ \lambda_i = 0 \quad \text{либо} \quad M_i(w, w_0) = 1 - \xi_i, \quad i = 1, \ldots, \ell; \\ \eta_i = 0 \quad \text{либо} \quad \xi_i = 0, \quad i = 1, \ldots, \ell; \end{cases}$$

Необходимые условия седловой точки функции Лагранжа

Функция Лагранжа:

$$\mathscr{L}(w, w_0; \xi, \lambda, \eta) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C),$$

Необходимые условия седловой точки функции Лагранжа:

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0 \qquad \Longrightarrow w = \sum_{i=1}^{\ell} \lambda_i y_i x_i;$$

$$\frac{\partial L}{\partial w_0} = -\sum_{i=1}^{\ell} \lambda_i y_i = 0 \qquad \Longrightarrow \sum_{i=1}^{\ell} \lambda_i y_i = 0;$$

$$\frac{\partial L}{\partial \xi_i} = -\lambda_i - \eta_i + C = 0 \qquad \Longrightarrow \eta_i + \lambda_i = C, \quad i = 1, \ldots, \ell.$$

Понятие опорного вектора и типизация объектов

Система условий KKT:

$$\begin{cases} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \quad \sum_{i=1}^{\ell} \lambda_i y_i = 0; \quad M_i(w, w_0) \geq 1 - \xi_i; \\ \xi_i \geq 0, \quad \lambda_i \geq 0, \quad \eta_i \geq 0, \quad \eta_i + \lambda_i = C; \\ \lambda_i = 0 \quad \text{либо} \quad M_i(w, w_0) = 1 - \xi_i; \\ \eta_i = 0 \quad \text{либо} \quad \xi_i = 0; \end{cases}$$

Определение.

Объект x_i называется опорным, если $\lambda_i \neq 0$.

Типизация объектов $x_i, \quad i = 1, \ldots, \ell$:

1. $\lambda_i = 0; \quad \eta_i = C; \quad \xi_i = 0; \quad M_i \geq 1$ — периферийный.
2. $0 < \lambda_i < C; \quad 0 < \eta_i < C; \quad \xi_i = 0; M_i = 1$ — опорный-граничный.
3. $\lambda_i = C; \quad \eta_i = 0; \quad \xi_i > 0; \quad M_i < 1$ — опорный-нарушитель.

Двойственная задача

$$\begin{cases} -\mathscr{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \to \min_\lambda; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0; \quad 0 \leq \lambda_i \leq C, \quad i = 1, \ldots, \ell \end{cases}$$

Решение прямой задачи выражается через решение двойственной:

$$\begin{cases} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \\ w_0 = \langle w, x_i \rangle - y_i, \quad \text{для любого } i : \lambda_i > 0, \quad M_i = 1. \end{cases}$$

Линейный классификатор с признаками $f_i(x) = \langle x, x_i \rangle$:

$$a(x) = \operatorname{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i \langle x, x_i \rangle - w_0 \right).$$

Двойственная задача. Нелинейное обобщение с ядром K

$$\begin{cases} -\mathscr{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j K(x_i, x_j) \to \min_\lambda; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0; \quad 0 \leq \lambda_i \leq C, \quad i = 1, \ldots, \ell \end{cases}$$

Решение прямой задачи выражается через решение двойственной:

$$\begin{cases} w = \sum_{i=1}^{\ell} \lambda_i y_i x_i; \\ w_0 = \langle w, x_i \rangle - y_i, \quad \text{для любого } i : \lambda_i > 0, \quad M_i = 1. \end{cases}$$

Линейный классификатор с признаками $f_i(x) = K(x, x_i)$:

$$a(x) = \operatorname{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i K(x, x_i) - w_0 \right).$$

Нелинейное обобщение SVM

Идея: заменить $\langle x, x' \rangle$ нелинейной функцией $K(x, x')$.
Переход к спрямляющему пространству,
как правило, более высокой размерности: $\psi : X \to H$.

Определение

Функция $K : X \times X \to \mathbb{R}$ — ядро, если $K(x, x') = \langle \psi(x), \psi(x') \rangle$
при некотором $\psi : X \to H$, где H — гильбертово пространство.

Теорема

Функция $K(x, x')$ является ядром тогда и только тогда, когда
она симметрична: $K(x, x') = K(x', x)$;
и неотрицательно определена:

$$\int_X \int_X K(x, x') g(x) g(x') \, dx \, dx' \geq 0 \quad \text{для любой} \quad g : X \to \mathbb{R}.$$

Конструктивные методы синтеза ядер

1. $K(x, x') = \langle x, x' \rangle$ — ядро;
2. константа $K(x, x') = 1$ — ядро;
3. произведение ядер $K(x, x') = K_1(x, x')K_2(x, x')$ — ядро;
4. $\forall \psi : X \to \mathbb{R}$ произведение $K(x, x') = \psi(x)\psi(x')$ — ядро;
5. $K(x, x') = \alpha_1 K_1(x, x') + \alpha_2 K_2(x, x')$ при $\alpha_1, \alpha_2 > 0$ — ядро;
6. $\forall \varphi : X \to X$ если K_0 ядро, то $K(x, x') = K_0(\varphi(x), \varphi(x'))$ — ядро;
7. если $s : X \times X \to \mathbb{R}$ — симметричная интегрируемая функция, то $K(x, x') = \int_X s(x, z)s(x', z)\, dz$ — ядро;
8. если K_0 — ядро и функция $f : \mathbb{R} \to \mathbb{R}$ представима в виде сходящегося степенного ряда с неотрицательными коэффициентами, то $K(x, x') = f(K_0(x, x'))$ — ядро;

Пример: спрямляющее пространство для квадратичного ядра

Пусть $X = \mathbb{R}^2$, $K(u, v) = \langle u, v\rangle^2$, где $u = (u_1, u_2)$, $v = (v_1, v_2)$.
Задача: найти пространство H и преобразование $\psi : X \to H$, при которых $K(x, x') = \langle \psi(x), \psi(x')\rangle_H$.
Разложим квадрат скалярного произведения:

$$\begin{aligned} K(u, v) &= \langle u, v\rangle^2 = \langle (u_1, u_2), (v_1, v_2)\rangle^2 \\ &= (u_1 v_1 + u_2 v_2)^2 \\ &= u_1^2 v_1^2 + u_2^2 v_2^2 + 2 u_1 v_1 u_2 v_2 \\ &= \langle (u_1^2, u_2^2, \sqrt{2} u_1 u_2), (v_1^2, v_2^2, \sqrt{2} v_1 v_2)\rangle. \end{aligned}$$

Таким образом,

$$H = \mathbb{R}^3, \quad \psi : (u_1, u_2) \to (u_1^2, u_2^2, \sqrt{2} u_1 u_2).$$

Линейной поверхности в пространстве H соответствует квадратичная поверхность в исходном пространстве X.

Примеры ядер

1. квадратичное ядро, $\dim H = \frac{1}{2}n(n+1)$

$$K(x, x') = \langle x, x' \rangle^2$$

2. полиномиальное с мономами степени d, $\dim H = C^d_{n+d-1}$

$$K(x, x') = \langle x, x' \rangle^d$$

3. полиномиальное с мономами степени $\leq d$

$$K(x, x') = (\langle x, x' \rangle + 1)^d$$

4. нейросеть с сигмоидными функциями активации

$$K(x, x') = \tanh(k_1 \langle x, x' \rangle - k_0), \quad k_0, k_1 \geq 0$$

5. сеть радиальных базисных функций (RBF ядро)

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

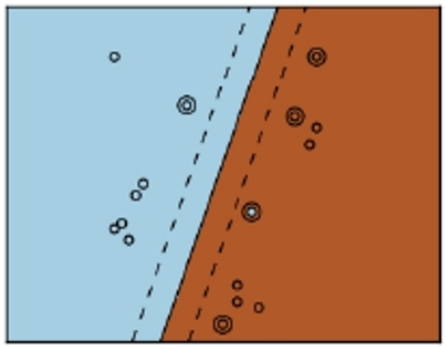
Классификация с различными ядрами

Гиперплоскость в спрямляющем пространстве соответствует нелинейной разделяющей поверхности в исходном.

Примеры с различными ядрами $K(x, x')$

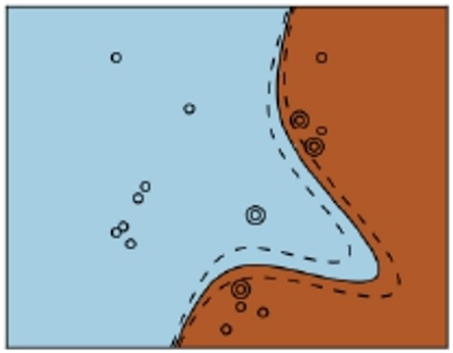
линейное

$\langle x, x' \rangle$



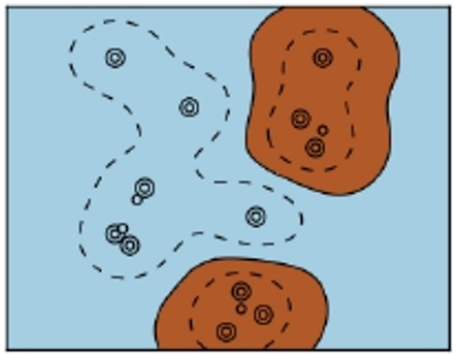
полиномиальное

$(\langle x, x' \rangle + 1)^d,\ d = 3$



гауссовское (RBF)

$\exp(-\gamma \|x - x'\|^2)$

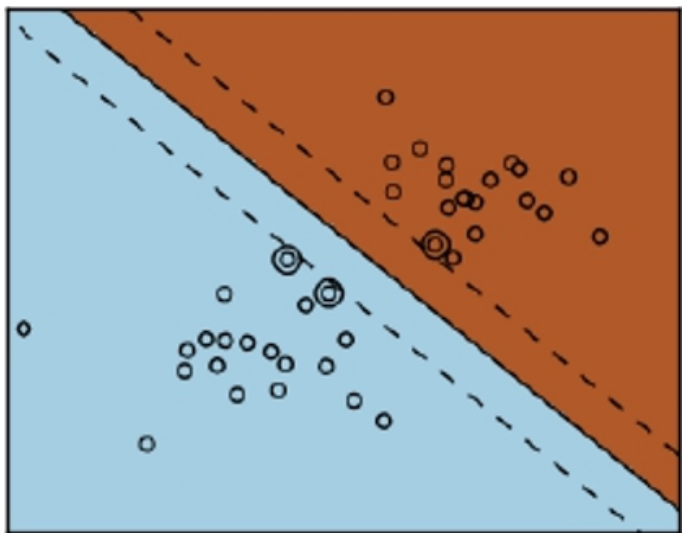


Влияние константы C на решение SVM

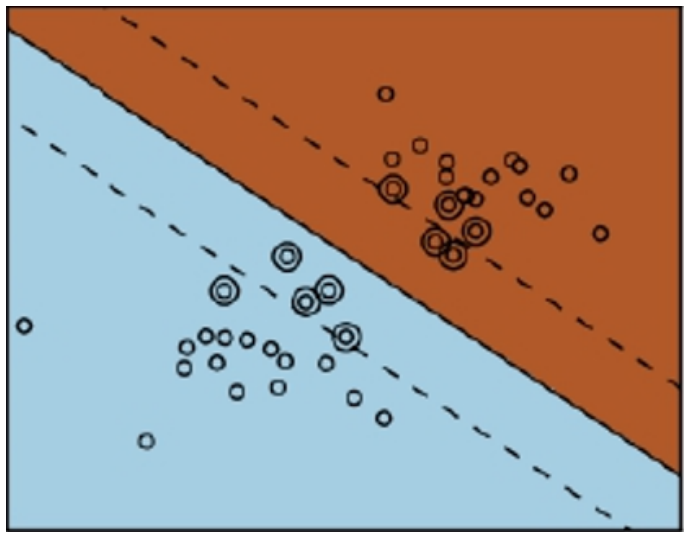
SVM — аппроксимация и регуляризация эмпирического риска:

$$\sum_{i=1}^{\ell}(1 - M_i(w, w_0))_+ + \frac{1}{2C}\|w\|^2 \to \min_{w,w_0}.$$

большой C
слабая регуляризация



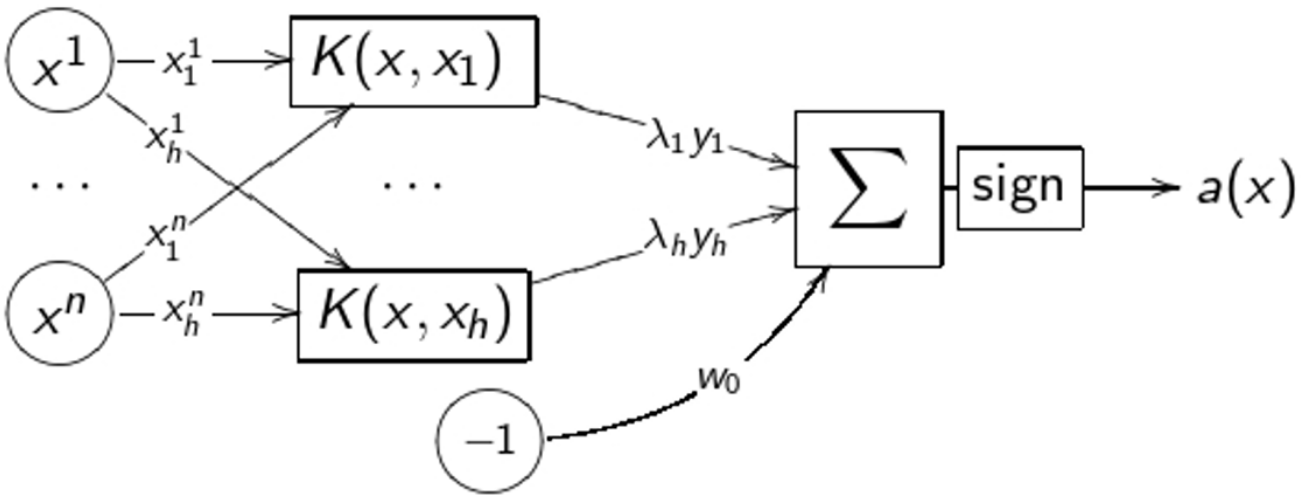
малый C
сильная регуляризация



SVM: двухслойная нейросеть и метрический классификатор

Переименуем объекты так, чтобы $x_1, \ldots, x_h$ были опорными.

$$a(x) = \text{sign}\left(\sum_{i=1}^{h} \lambda_i y_i K(x, x_i) - w_0\right).$$



Первый слой вместо скалярных произведений вычисляет ядра.

Веса первого слоя — это сами опорные объекты.

Метрический классификатор, если K — функция близости.

Преимущества и недостатки SVM

Преимущества SVM перед двухслойными нейронными сетями:

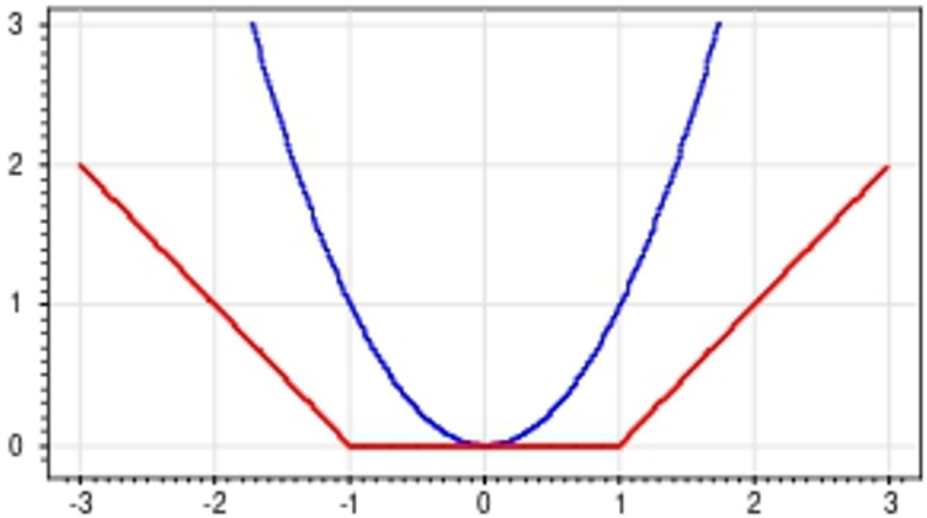
- задача выпуклого квадратичного программирования имеет единственное решение
- число нейронов скрытого слоя определяется автоматически — это число опорных векторов

Недостатки классического SVM:

- нет общих подходов к оптимизации $K(x, x')$ под задачу
- на больших данных SVM обучается медленнее SG
- нет «встроенного» отбора признаков
- приходится подбирать константу C

SVM-регрессия

Модель регрессии: $a(x) = \langle x, w \rangle - w_0$, $w \in \mathbb{R}^n$, $w_0 \in \mathbb{R}$.
Функция потерь: $\mathscr{L}(\epsilon) = (|\epsilon| - \delta)_+$ в сравнении с $\mathscr{L}(\epsilon) = \epsilon^2$:



Постановка задачи:

$$\sum_{i=1}^{\ell} (|\langle w, x_i \rangle - w_0 - y_i| - \delta)_+ + \frac{1}{2C}\|w\|^2 \to \min_{w, w_0}.$$

Задача решается путём замены переменных и сведения к задаче квадратичного программирования.

SVM-регрессия

Замена переменных:

$$\xi_i^+ = (\langle w, x_i \rangle - w_0 - y_i - \delta)_+;$$
$$\xi_i^- = (-\langle w, x_i \rangle + w_0 + y_i - \delta)_+.$$

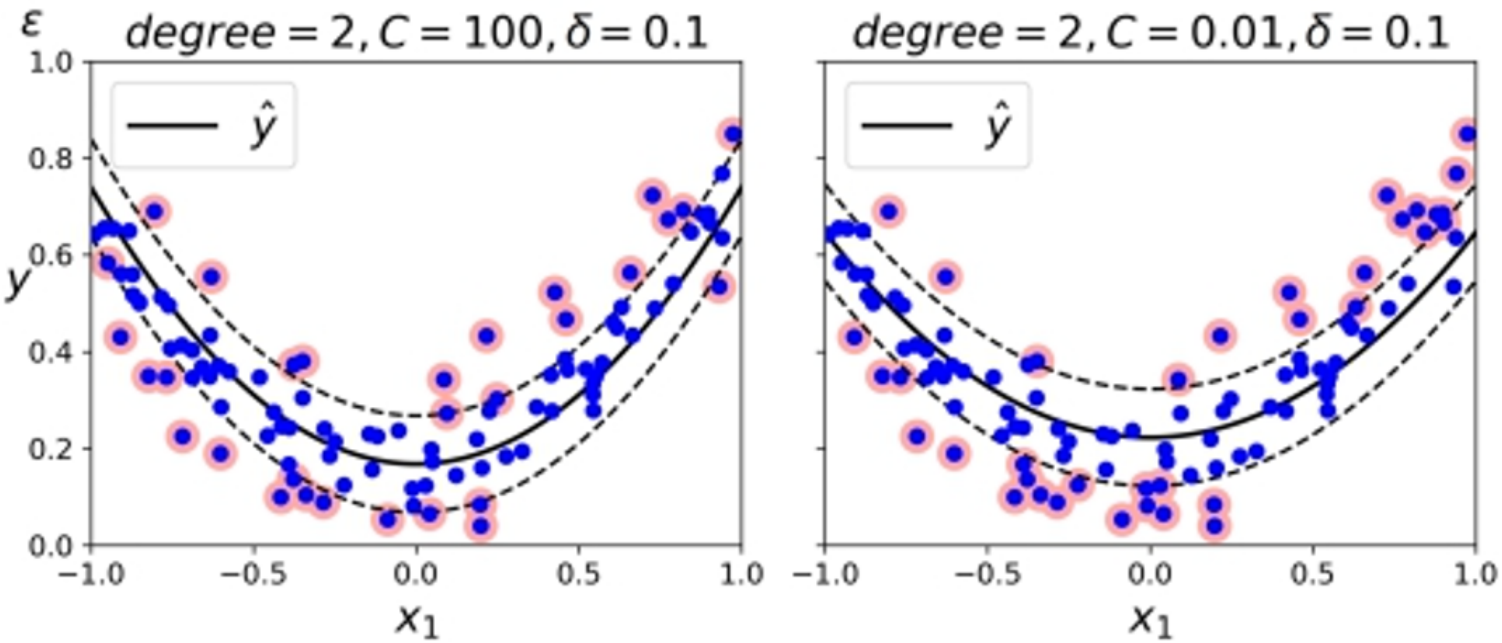
Постановка задачи SVM-регрессии:

$$\begin{cases} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{\ell}(\xi_i^+ + \xi_i^-) \to \min_{w, w_0, \xi^+, \xi^-}; \\ y_i - \delta - \xi_i^- \le \langle w, x_i \rangle - w_0 \le y_i + \delta + \xi_i^+, \quad i = 1, \ldots, \ell; \\ \xi_i^- \ge 0, \quad \xi_i^+ \ge 0, \quad i = 1, \ldots, \ell. \end{cases}$$

- выпуклая задача квадратичного программирования
- решение единственно
- решение выражается через опорные векторы
- возможна замена $\langle x, x_i \rangle$ ядром $K(x, x_i)$

SVM-регрессия. Пример 1

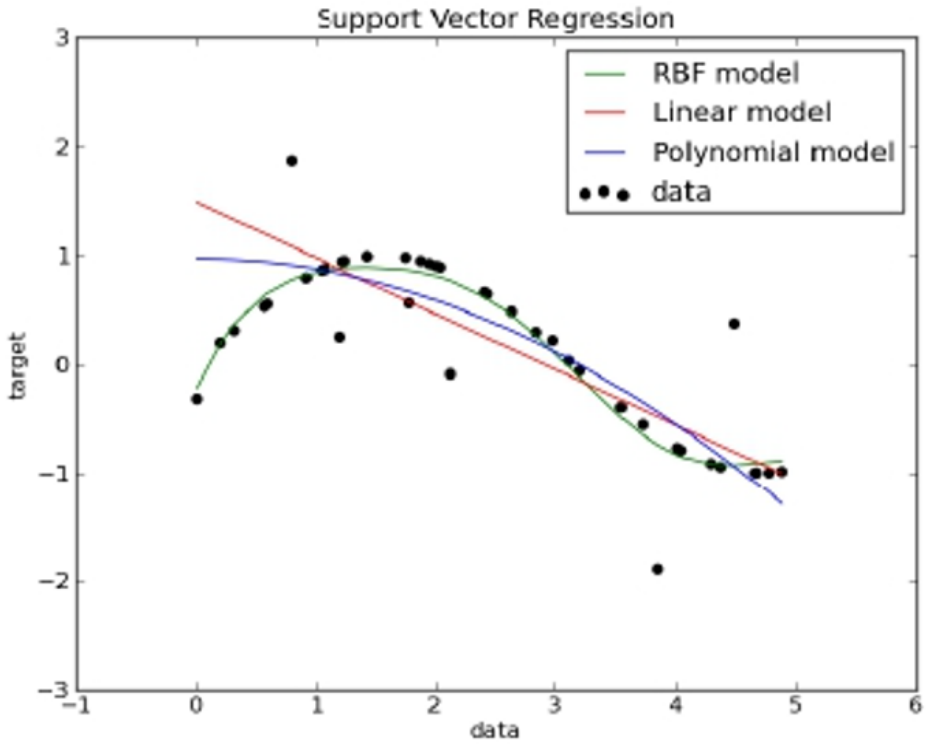
SVM-регрессия с полиномиальным ядром степени 2:



- выделены опорные векторы
- результат слабо зависит от константы C

SVM-регрессия. Пример 2

Сравнение SVM-регрессии с гауссовским (RBF) ядром, линейной и полиномиальной регрессией:



- Удачный выбор ядра имеет значение!

1-norm SVM (LASSO SVM)

Аппроксимация эмпирического риска с L1-регуляризацией:

$$\sum_{i=1}^{\ell}(1 - M_i(w, w_0))_+ + \mu \sum_{j=1}^{n} |w_j| \to \min_{w, w_0}.$$

- + Отбор признаков с параметром селективности μ: чем больше μ, тем меньше признаков останется
- - Слишком агрессивный отбор признаков:
  - по мере увеличения μ признак может быть отброшен,
  - хотя у существенно зависит от него,
  - даже когда ещё не все шумовые признаки отброшены

1-norm SVM (LASSO SVM)

Аппроксимация эмпирического риска с L1-регуляризацией:

$$\sum_{i=1}^{\ell}(1 - M_i(w, w_0)) + \mu \sum_{j=1}^{n} |w_j| \to \min_{w, w_0}.$$

Почему L1-регуляризатор приводит к отбору признаков?
Замена переменных: $u_j = \frac{1}{2}(|w_j| + w_j)$, $v_j = \frac{1}{2}(|w_j| - w_j)$.
Тогда $w_j = u_j - v_j$ и $|w_j| = u_j + v_j$.

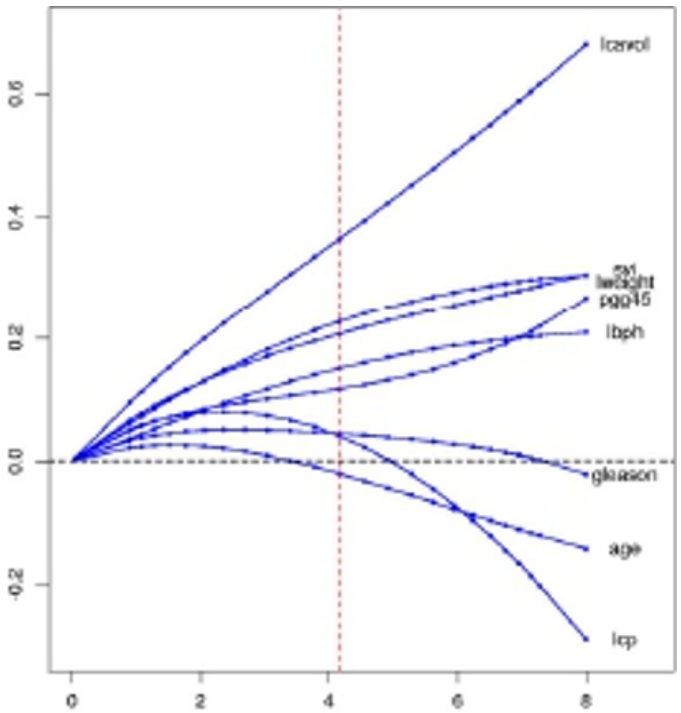
$$\begin{cases} \sum_{i=1}^{\ell}(1 - M_i(u - v, w_0))_+ + \mu \sum_{j=1}^{n}(u_j + v_j) \to \min_{u,v} \\ u_j \geq 0, \quad v_j \geq 0, \quad j = 1, \ldots, n; \end{cases}$$

чем больше μ, тем больше индексов j таких, что $u_j = v_j = 0$,
но тогда $w_j = 0$, значит, признак не учитывается.

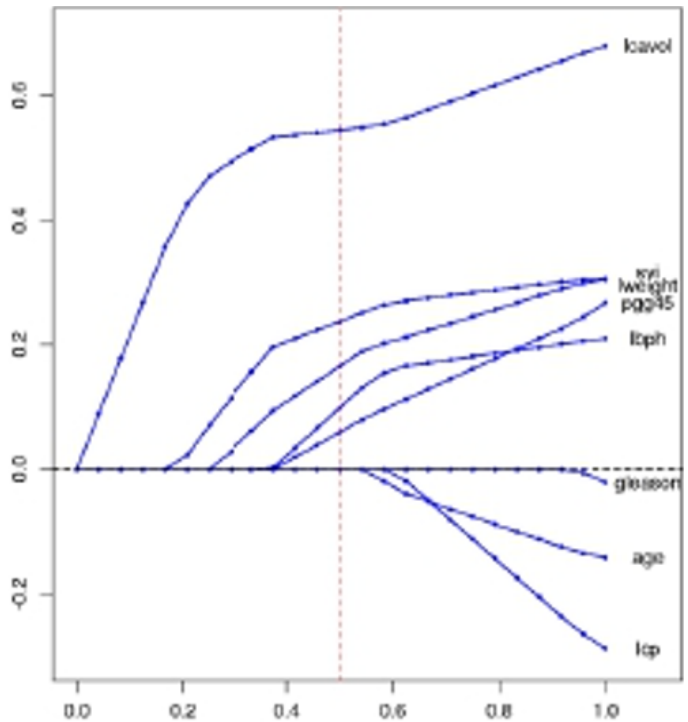
Сравнение L_2 и L_1 регуляризации

Зависимость весов w_j от коэффициента $\frac{1}{\mu}$

L_2 **регуляризатор:** $\mu \sum_j w_j^2$



L_1 **регуляризатор:** $\mu \sum_j |w_j|$



Задача из UCI: prostate cancer (диагностика рака)

Doubly Regularized SVM (Elastic Net SVM)

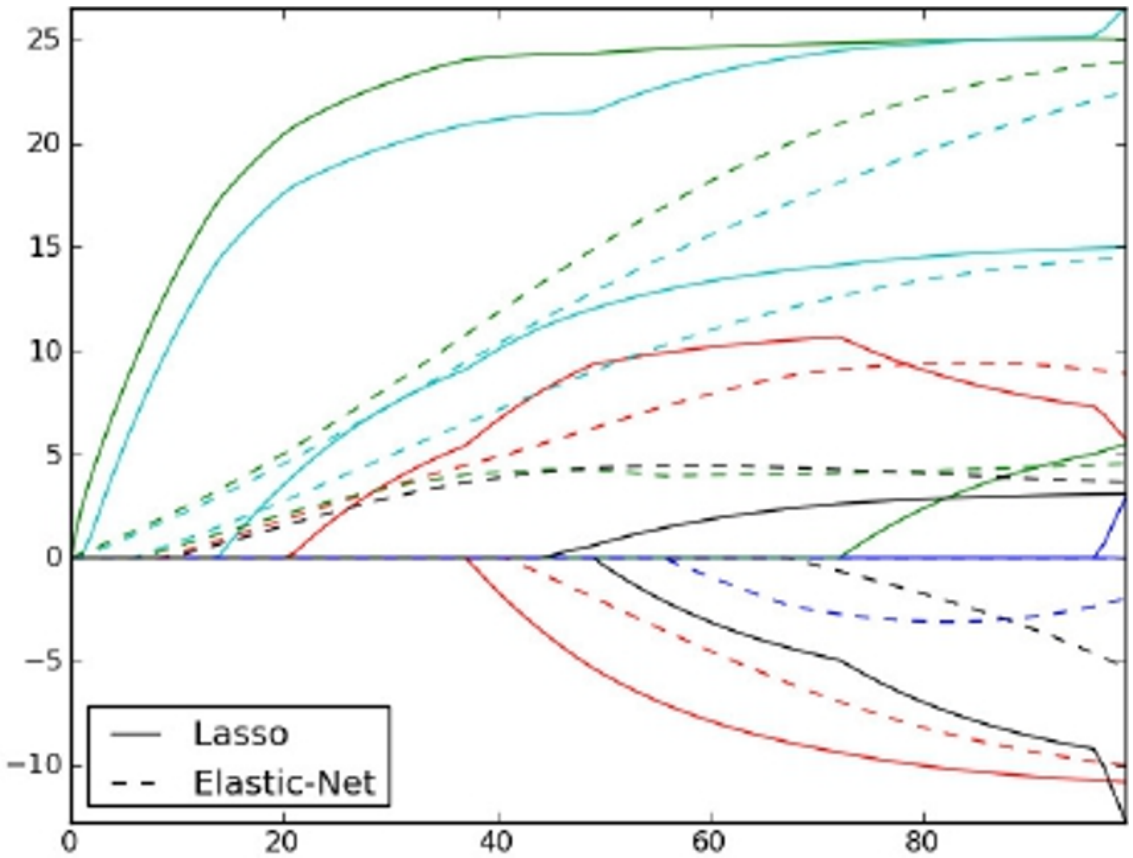
$$C\sum_{i=1}^{\ell}(1 - M_i(w, w_0))_+ + \mu\sum_{j=1}^{n}|w_j| + \frac{1}{2}\sum_{j=1}^{n}w_j^2 \to \min_{w,w_0}$$

.

- \+ Параметр селективности μ управляет отбором признаков: чем больше μ, тем меньше признаков останется
- \+ Есть эффект группировки (grouping effect): значимые зависимые признаки отбираются вместе
- \- Шумовые признаки также группируются и могут вместе оставаться в модели
- \- Приходится подбирать два параметра регуляризации μ, τ (есть специальные методы — regularization path)

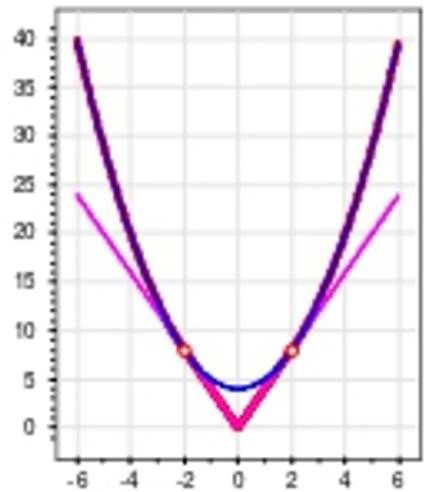
Doubly Regularized SVM (Elastic Net SVM)

Elastic Net менее жёстко отбирает признаки.
Зависимости весов w_j от коэффициента $\log \frac{1}{\mu}$:



Support Features Machine (SFM)

$$C\sum_{i=1}^{\ell}(1-M_i(w,w_0))+\sum_{j=1}^{n}R_\mu(w_j)\to\min_{w,w_0}$$



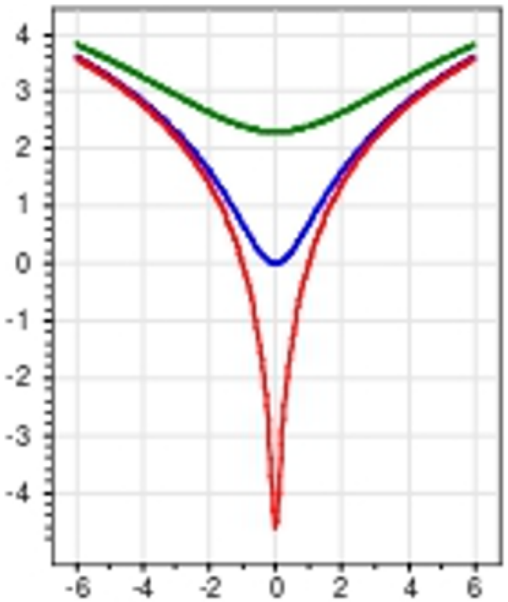
$$R_\mu(w_j)=\begin{cases}2\mu|w_j|, & |w_j|\le\mu\\ \mu^2+w_j^2, & |w_j|>\mu\end{cases}$$

- + Только один параметр регуляризации μ
- + Отбор признаков с параметром селективности μ
- + Эффект группировки: значимые зависимые признаки ($|w_j|>\mu$) входят в решение совместно (как в Elastic Net)
- + Шумовые признаки ($|w_j|<\mu$) не группируются и подавляются независимо друг от друга (как в LASSO)

Relevance Features Machine (RFM)

$$C\sum_{i=1}^{\ell}(1-M_i(w,w_0))_+ + \sum_{j=1}^{n}\ln(w_j^2+\frac{1}{\mu}) \to \min_{w,w_0}$$

$$R(w) = \ln(w^2 + \frac{1}{\mu}) \text{при} \mu = 0.1, 1, 100$$



- + Только один параметр регуляризации μ
- + Отбор признаков с параметром селективности μ
- + Есть эффект группировки
- + Лучше отбирает набор значимых признаков, когда они только совместно обеспечивают хорошее решение

Метод релевантных векторов RVM (Relevance Vector Machine)

Положим, как и в SVM, при некоторых $\lambda_i \geq 0$

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i,$$

причём опорным векторам x_i соответствуют $\lambda_i \neq 0$.

Проблема: Какие из коэффициентов λ_i лучше обнулить?

Идея: пусть регуляризатор зависит не от w, а от λ_i.

Пусть λ_i независимые, гауссовские, с дисперсиями α_i:

$$p(\lambda) = \frac{1}{(2\pi)^{\ell/2}\sqrt{\alpha_1 \cdots \alpha_\ell}} \exp\left(-\sum_{i=1}^{\ell} \frac{\lambda_i^2}{2\alpha_i}\right);$$

$$\sum_{i=1}^{\ell}(1 - M_i(w(\lambda), w_0)) + \frac{1}{2}\sum_{i=1}^{\ell}\left(\ln \alpha_i + \frac{\lambda_i^2}{\alpha_i}\right) \to \min_{\lambda,\alpha}.$$

Преимущества и недостатки RVM

Преимущества:

- Опорных векторов, как правило, меньше (более «разреженное» решение).
- Шумовые выбросы уже не входят в число опорных.
- Не надо искать параметр регуляризации (вместо этого α_i оптимизируются в процессе обучения).
- Аналогично SVM, можно использовать ядра.

Недостатки:

- Не всегда есть преимущество по качеству классификации.

Резюме по линейным классификаторам

- SVM — лучший метод линейной классификации
- С помощью ядер (kernel trick) SVM изящно обобщается для нелинейной классификации и нелинейной регрессии
- Аппроксимация пороговой функции потерь $\mathscr{L}(M)$ увеличивает зазор и повышает надёжность классификации
- Регуляризация увеличивает зазор, устраняет мультиколлинеарность и уменьшает переобучение
- Негладкость функции потерь приводит к отбору объектов
- Негладкость регуляризатора приводит к отбору признаков